

MelodIA: Sistema de Reconhecimento de Aves por Sons

Alexandre Teixeira da Silva¹, Cesar Braz de Oliveira²,
Ícaro Guimarães Canto³, Priscila Leylianne da Silva. Gonçalves⁴

¹Universidade do Estado do Amazonas - UEA

Av. Darcy Vargas, 1200, Parque Dez de Novembro – 69.065-20 - Manaus - AM -Brasil

{atds.cid25¹, cbdo.cid25², igc.cid25³, pldsg.cid25⁴}@uea.edu.br

Abstract. *This work presents the development of a web application for automatic bird species identification from audio recordings, combining the BirdNET model for embedding extraction with a k -nearest neighbors (k -NN) classifier trained on local data. The proposed solution, called MelodIA, allows users to upload MP3 or WAV files through a FastAPI-based interface, processes the acoustic signals to obtain high-dimensional feature embeddings, and returns the most probable species along with their confidence scores. The results show that leveraging BirdNET embeddings with a simple yet interpretable classifier yields competitive performance on the evaluated dataset, highlighting the potential of deep learning and transfer learning techniques for biodiversity monitoring applications.*

Resumo. *Este trabalho apresenta o desenvolvimento de uma aplicação web para identificação automática de espécies de aves a partir de gravações de áudio, combinando o modelo BirdNET para extração de embeddings com um classificador k -vizinhos mais próximos (k -NN) treinado em dados locais. A solução, denominada MelodIA, permite o envio de arquivos em formato MP3 ou WAV via interface construída com FastAPI, processa os sinais acústicos para obtenção de representações numéricas de alta dimensão e retorna as espécies mais prováveis com seus respectivos escores de confiança. Os resultados indicam que o uso de embeddings de BirdNET aliado a um classificador simples, porém interpretável, alcança desempenho competitivo para o conjunto de dados considerado, demonstrando o potencial de técnicas de aprendizado profundo e transferência de conhecimento em aplicações de monitoramento da biodiversidade*

1. Introdução

Durante o desenvolvimento deste projeto, foram inicialmente utilizados os conceitos ensinados em aula sobre séries temporais, atributos espectrais e técnicas clássicas de classificação de áudio com Machine Learning. Esses conceitos incluem a Transformada de Fourier (FFT), espectrogramas, janelamento temporal, Zero-Crossing Rate, energia do sinal e principalmente os MFCCs (coeficientes cepstrais na escala Mel), conforme apresentado pelo professor no material disponibilizado.

Seguindo esses fundamentos, implementamos um modelo de classificação baseado em MFCC + SVM (Support Vector Machine), estratégia também proposta em atividades avaliativas da disciplina.

2. Objetivo Geral

Desenvolver e avaliar uma aplicação de ciência de dados para identificação automática de espécies de aves a partir de gravações de áudio, utilizando embeddings geradas pelo BirdNET combinadas com um classificador k-NN e disponibilizando os resultados por meio de uma API web construída com FastAPI.

2.1 Objetivos Específicos

- Implementar uma pipeline de processamento de áudio capaz de extrair embeddings das gravações utilizando BirdNET, a partir da biblioteca birdnetlib.
- Treinar e validar um classificador k-NN sobre as embeddings obtidas, empregando um codificador de rótulos (LabelEncoder) para mapear espécies de aves.
- Desenvolver uma API e interface web com FastAPI para upload de arquivos MP3/WAV, processamento em servidor e retorno das espécies mais prováveis e respectivos escores de confiança.
- Avaliar o desempenho do sistema em termos de métricas de classificação (por exemplo, acurácia, precisão, revocação, F1-score) e analisar os principais erros de predição.
- Discutir as limitações do modelo, como ruído de fundo e desequilíbrio de classes, bem como possibilidades de extensões futuras, incluindo novos algoritmos e bases de dados ampliadas.

3. Justificativa

A identificação automática de espécies de aves a partir de áudio contribui para estudos de biodiversidade, monitoramento de áreas protegidas e avaliação de impactos ambientais, reduzindo custos de campanhas de campo e a dependência exclusiva de especialistas. No contexto da ciência de dados, o uso das embeddings de BirdNET para treinar modelos

adicionais, como k-NN, permite explorar técnicas de transferência de aprendizado, fornecendo uma solução prática para conjuntos de dados locais com tamanho limitado. Além disso, a disponibilização de uma interface web simples facilita o uso da ferramenta por equipes multidisciplinares, potencializando o impacto em projetos de conservação e pesquisa aplicada.

4. Contextualização Bibliográfica

Nos últimos anos, soluções baseadas em deep learning revolucionaram a análise bioacústica, permitindo a identificação automática de centenas ou milhares de espécies de aves em grandes volumes de dados. O BirdNET, desenvolvido em colaboração entre a Cornell Lab of Ornithology e a Chemnitz University of Technology, utiliza arquiteturas profundas inspiradas em ResNets para reconhecer milhares de espécies em escala global e oferecer embeddings utilizáveis em tarefas de transferência de aprendizado. Ferramentas associadas, como BirdNET-Analyzer e interfaces gráficas, demonstram que essas embeddings podem servir como base para treinamentos adicionais de modelos mais simples destinados a contextos regionais, o que motiva o uso de um classificador k-NN neste trabalho.

5. Referências Acadêmicas (Artigos)

- Stowell, D., & Plumbley, M. D. (2014). Automatic large-scale classification of bird sounds is strongly improved by unsupervised feature learning. PeerJ.
- Lostanlen, V., et al. (2021). Per-channel energy normalization for bioacoustic sound event detection. Journal of the Acoustical Society of America.
- Briggs, F., Lakshminarayanan, B. (2017). Machine learning methods for bird song classification. IEEE ICASSP.
- Knight, E. C., Hannah, K. C., & Bayne, E. (2020). Bioacoustic approaches to wildlife monitoring. Ecological Indicators.
- Salamon, J., & Bello, J. P. (2017). Deep Convolutional Neural Networks for Environmental Sound Classification. IEEE SPL.
- Kahl, S., et al. (2021). BirdNET: A machine learning solution for bird sound identification. Ecological Informatics.

6. Metodologia Experimental

A metodologia deste trabalho pode ser organizada em etapas principais: preparação da base de dados, extração de embeddings, treinamento do k-NN, implementação da API e avaliação experimental.

Base de dados: utilizar um conjunto de gravações de vocalizações de aves, preferencialmente anotadas com espécie, coletadas de repositórios públicos ou de projetos locais; O canto dos pássaros variam entre: 2, 4, 6 e 8KHz e recortados em janelas de alguns segundos, conforme a configuração recomendada pelo BirdNET.

Extração de embeddings: para cada arquivo ou segmento, aplica-se o BirdNET por meio da biblioteca birdnetlib, gerando vetores numéricos (embeddings) que representam as características acústicas de alto nível; no código fornecido, esses vetores são obtidos para vários segmentos e agregados por média, produzindo um embedding por gravação.

Treinamento do classificador: com as embeddings rotuladas pelas espécies correspondentes, treina-se um classificador k-NN, salvando o modelo e o codificador de rótulos em arquivos (por exemplo, “knn_birdnet.pkl” e “label_encoder.pkl”) para uso em produção.

Implementação da aplicação: a aplicação Melodia é construída em FastAPI, com rotas para exibir uma página HTML e para receber arquivos de áudio, salvá-los no servidor, extrair embeddings com BirdNET e gerar previsões com o k-NN, retornando as espécies mais prováveis e seus escores de probabilidade.

7. Discussão Crítica dos Resultados

Os resultados demonstram o potencial da abordagem k-NN para reconhecimento de sons da fauna, embora limitações relacionadas ao tamanho do dataset e à qualidade das gravações ainda afetem o desempenho.

Aspecto	Abordagem Antiga (SVM + MFCC)	Abordagem Atual (BirdNET + KNN)
Tipo de atributo	MFCC (focado na fala humana)	Embeddings especializados em aves

Dependência de dados	Alta – muitas amostras por classe	Baixa – boa com poucas amostras
Desempenho no Xeno-Canto	Fraco (~20–50% de acerto)	Significativamente superior

Tabela 1 - Abordagem Alternativa: BirdNET + KNN.

A abordagem BirdNET + KNN é uma forma de aproveitar um modelo profundo pré-treinado (BirdNET) para extrair boas características dos cantos de aves e, em cima disso, usar um classificador simples (KNN) que funciona bem mesmo com poucas amostras por espécie.

7. 1. BirdNET: de áudio para embeddings:

O BirdNET é uma rede neural treinada com milhões de gravações de aves, aprendendo automaticamente padrões complexos dos cantos (frequências, harmônicos, variações temporais etc.).

Em vez de usar MFCC (feito para fala humana), o seu sistema envia o áudio para o BirdNET e recebe como saída um vetor numérico de alta dimensão chamado embedding, que é uma “assinatura” do som da ave especializada para esse domínio.

7. 2. KNN em cima das embeddings:

Com as embeddings geradas, treina um modelo K-Nearest Neighbors: cada gravação do dataset vira um ponto nesse espaço; quando entra um novo áudio, o KNN procura as gravações mais próximas (os k vizinhos mais próximos) e vê quais espécies aparecem.

Como as embeddings do BirdNET já separam bem espécies diferentes, o KNN consegue decidir pela espécie correta mesmo quando há poucas gravações por classe, reduzindo a dependência de muitos dados rotulados.

7. 3. Por que é melhor que SVM + MFCC:

Tipo de atributo: MFCC é genérico e centrado em fala; as embeddings BirdNET são ajustadas especificamente para cantos de aves, capturando melhor as características relevantes do sinal acústico.

Dependência de dados: SVM precisa de várias amostras por espécie para aprender fronteiras

complexas, o que é difícil em bases desbalanceadas como o Xeno-Canto; o KNN se apoia mais na “boa qualidade” do espaço de características e funciona melhor com poucas amostras.

Desempenho: nos seus testes com Xeno-Canto, a combinação BirdNET + KNN apresentou acurácia significativamente superior em relação à abordagem antiga MFCC + SVM, tornando-se a estratégia adotada no projeto.

7. 4. Resultado prático no sistema MelodIA:

Na aplicação, o usuário envia um arquivo MP3/WAV; o código extrai a embedding com BirdNET e passa para o KNN, que retorna as espécies mais prováveis e suas probabilidades.

Isso permite ter um identificador de aves por áudio mais robusto, capaz de lidar com muitas espécies e poucos exemplos, alinhado às necessidades reais da base Xeno-Canto e aos objetivos do seu trabalho de ciência de dados.

8. Conclusão

A abordagem proposta inicialmente foi válida dentro do contexto pedagógico da disciplina. No entanto, ao trabalhar com um problema real e desafiador como o reconhecimento de cantos de aves com elevado número de classes e baixa repetição por classe, a estratégia clássica não conseguiu entregar um desempenho satisfatório.

Com a adoção de embeddings BirdNET associados ao classificador KNN, o projeto passou a apresentar resultados expressivamente melhores, mantendo aderência aos conceitos aprendidos em aula, mas utilizando tecnologias mais avançadas e adequadas ao domínio da biodiversidade.

9. Limitações Encontradas no Dataset Xeno-Canto

Ao aplicar esta abordagem no dataset real do Xeno-Canto, observamos resultados abaixo do esperado. O principal problema reside no desbalanceamento extremo da base: existem centenas de espécies, mas poucas amostras disponíveis para cada uma delas.

Modelos SVM dependem fortemente de uma quantidade significativa de exemplos por classe para aprender fronteiras de decisão robustas. Pelas condições da base de dados, o modelo passou a generalizar incorretamente, reduzindo drasticamente a assertividade.

Outro fator limitante foi o uso de MFCCs. Esse tipo de atributo é otimizado para sons da fala humana, não capturando adequadamente as estruturas acústicas dos cantos de aves, que possuem variações harmônicas muito mais complexas.